

Xây dựng hệ thống phát hiện tin giả tiếng Việt

(Hệ thống ShieldAI)

Sinh viên: Hà Minh Chiến - 2202095

Giảng viên hướng dẫn: ThS. Trần Ngọc Anh

Ngành: Khoa Học Máy Tính

1. Đặt vấn đề & Lý do chọn đề tài

- **Thực trạng:** Sự bùng nổ của mạng xã hội khiến tin giả lây lan nhanh, gây hậu quả nghiêm trọng.
- **Hạn chế của AI hiện tại:** Các mô hình học sâu truyền thống thường mang tính chất "**hộp đen**" (black-box), khó diễn giải quyết định cho người dùng.
- **Giải pháp:** Hệ thống **ShieldAI** ra đời nhằm cung cấp công cụ kiểm chứng thông tin:
 - **Độ chính xác cao**
 - **Tính minh bạch** (Có khả năng giải thích)

2. Ý nghĩa tên gọi "ShieldAI"

- **"Shield" (Lá chắn) + "AI" (Trí tuệ nhân tạo)**
- **Sứ mệnh:** Xây dựng một lá chắn công nghệ thông minh và tự động.
- **Mục tiêu:** Bảo vệ người dùng mạng xã hội tại Việt Nam trước các luồng thông tin độc hại, sai lệch và lừa đảo.

3. Kiến trúc Tổng thể Hệ thống

- **Frontend (Next.js 14):** Giao diện tương tác người dùng thân thiện, ổn định.
- **Backend (FastAPI):** Xử lý bất đồng bộ, tốc độ cao.
- **Core AI:** Mô hình ngôn ngữ lớn **PhoBERT** (Tối ưu hóa bằng Fine-tuning).
- **Data Flow:** Tích hợp **Web Crawler** (BeautifulSoup) tự động trích xuất nội dung từ URL bài báo.

4. Xử lý Ngôn ngữ Tự nhiên với PhoBERT

- **Mô hình PhoBERT:** Kiến trúc Transformer tối ưu chuyên biệt cho tiếng Việt.
- **Phương pháp tiếp cận:** Phân loại chuỗi (Sequence Classification).
- **Quy trình:**
 - Trích xuất đặc trưng ngữ nghĩa từ token `[CLS]`.
 - Khắc phục hạn chế của các phương pháp đếm từ truyền thống (như TF-IDF).
 - Khả năng nắm bắt cấu trúc ngữ pháp phức tạp.

5. Động cơ Giải thích (Explanation Engine)

Giải quyết vấn đề "Hộp đen" của AI thông qua Cơ chế Heuristics (Rule-based):

- **Phân tích Cảm xúc (Sentiment):** Phát hiện ngôn từ kích động.
- **Mật độ In hoa:** Phát hiện việc lạm dụng VIẾT HOA ĐỂ GÂY CHÚ Ý.
- **Từ ngữ Giật gân:** Đếm các từ khóa clickbait ("sốc", "kinh hoàng").
- **Tính chủ quan:** Tỷ lệ từ ngữ thể hiện quan điểm cá nhân thay vì sự thật khách quan.

Mỗi dự đoán của mô hình đều đi kèm với các bằng chứng cụ thể.

6. Dữ liệu Huấn luyện & Tiền xử lý

- **Quy mô:** Hơn **22.000** bài báo.
- **Làm sạch (TextCleaner):** Khử nhiễu HTML, loại bỏ trùng lặp (Deduplication) để tránh rò rỉ dữ liệu (Data Leakage).
- **Tách từ (Tokenization):** Sử dụng thư viện **PyVi** chuẩn hóa tiếng Việt.
- **Phân chia:** Stratified Split (76% Train - 12% Validation - 12% Test) giúp cân bằng nhãn phân loại.

7. Cơ chế Phân loại đa mức độ (Thresholds)

Không sử dụng phân loại nhị phân (Thật/Giả) cứng nhắc, ShieldAI áp dụng 3 mức độ tinh tế:

1. **Tin thật:** Xác suất $< 35\%$ (Vùng an toàn)
2. **Đáng ngờ:** $35\% - 74\%$ (Cần xác minh thêm)
3. **Tin giả:** Xác suất $\geq 75\%$ (Cảnh báo đỏ)

Điểm cắt 75% được chọn khắt khe để bảo vệ độ chuẩn xác (Precision), tránh đánh oan tin chính thống.

8. Kết quả Thử nghiệm Nội bộ (Internal Test)

Đánh giá trên tập kiểm thử độc lập (2.716 mẫu):

Mô hình (Model)	Accuracy	F1-Score
Logistic Regression (TF-IDF)	82.15%	80.82%
Support Vector Machine (SVM)	85.34%	84.10%
BiLSTM (Word2Vec)	89.67%	88.66%
ShieldAI (PhoBERT Fine-tuned)	96.32%	93.42%

Hiệu năng vượt trội nhờ khả năng thấu hiểu ngữ cảnh sâu của PhoBERT.

9. Kiểm thử Độc lập & Chịu tải

- **External Validation:** Thử nghiệm trên 100 bài báo mới xuất bản năm 2026.
 - Kết quả: Đạt độ chính xác **91.5%**.
 - Chứng minh mô hình không bị "học vẹt" (Overfitting).
- **Latency & Throughput (JMeter):**
 - Tốc độ phản hồi (End-to-End): **< 1 giây**.
 - Thông lượng: 15-20 requests/second.
 - Đáp ứng tốt nhu cầu xử lý thời gian thực.

10. Phân tích Sai số (Error Analysis)

- **Dương tính giả (Báo nhầm tin thật thành tin giả):**
 - Xảy ra ở các bài báo hình sự/thể thao dùng văn phong giật gân (Clickbait) quá giống tin lừa đảo.
- **Âm tính giả (Bỏ lọt tin giả):**
 - Xảy ra khi tin giả được ngụy trang cực kỳ tinh vi dưới dạng văn bản hành chính nhà nước (VD: thông báo phạt nguội).

11. Trải nghiệm Người dùng (UX)

- Người dùng chỉ cần sao chép và **dán URL bài báo**.
- Hệ thống tự động bóc tách và phân tích.
- Hiển thị trực quan:
 - Điểm số tin cậy (Confidence Score).
 - Nhãn cảnh báo (Verdict).
 - Chi tiết các nguyên nhân (Heuristic Explanations).

12. Tổng kết & Đóng góp

- **Thành tựu cốt lõi:**
 - Áp dụng thành công kiến trúc PhoBERT vào bài toán thực tế.
 - Xây dựng hệ thống Web phân tán (Client-Server) hoàn chỉnh.
 - Giải quyết bài toán giải thích (XAI) thông qua Heuristics minh bạch.
- **Ý nghĩa:** Chuyển giao AI từ phòng thí nghiệm thành một ứng dụng thiết thực, bảo vệ người dùng mạng.

13. Hướng phát triển tương lai

- Cải tiến nhận diện bằng phương pháp **Fact-Checking** (Kiểm chứng sự kiện).
- Tích hợp **Tri thức Đồ thị (Knowledge Graph)**.
- Áp dụng kỹ thuật RAG (Retrieval-Augmented Generation) để đối chiếu thông tin với các nguồn báo chí chính thống theo thời gian thực.

Xin chân thành cảm ơn!

Q & A

Cảm ơn Quý Thầy Cô và Hội đồng đã lắng nghe.